UFMG UNIVERSIDADE FEDERAL DE MINAS GERAIS

Universidade Federal de Minas Gerais
Curso de Engenharia de Sistemas
Trabalho de Conclusão de Curso I

Visão Geral do Projeto

Sistema IoT para Monitoramento da Presença de Estudantes em Transporte Escolar Rural por Reconhecimento de Voz e Vídeo

Aluna: Fernanda Andrade Bicalho da Cruz

Orientador: Janier Arias García

Coorientador: Frederico Gualberto Ferreira Coelho

Histórico de revisões

Versão	Data	Autor	Descrição
01.00	12/out/2026	Fernanda Andrade Bicalho da Cruz	Versão inicial, entregue em 18/10/2026.

Sumário

1 Introdução . . . 3
1.1 Propósito . . . 3
1.2 Público Alvo . . . 3
1.3 Motivação e justificativa . . . 3
1.4 Objetivos . . . 4
1.5 Local de realização . . . 4
1.6 Visão geral do documento . . . 4
2 Visão Geral do Trabalho . . . 4
2.1 Escopo do trabalho . . . 5
2.2 Revisão bibliográfica . . . 6
3 Metodologia e Cronograma . . . 8
3.1 Atividades do TCC I . . . 8
3.2 Atividades do TCC II . . . 11
3.3 Cronograma . . . 12

REFERÊNCIAS . . . 12

1 Introdução

1.1 Propósito

Este documento especifica o trabalho a ser desenvolvido pela aluna de Engenharia de Sistemas Fernanda Andrade Bicalho da Cruz, fornecendo ao professor orientador e ao professor da disciplina as informações necessárias para sua avaliação e aprovação. Além disso, o documento servirá como base para o desenvolvimento do projeto ao longo dos dois semestres de sua realização e também pode servir para gerar partes dos textos das monografias de TCC I e TCC II.

1.2 Público Alvo

Este documento se destina à aluna e aos profissionais envolvidos na orientação de seu trabalho de conclusão de curso.

1.3 Motivação e justificativa

Problema. O transporte escolar rural é essencial para garantir o acesso à educação em regiões afastadas, mas o controle de quais alunos embarcam e desembarcam dos ônibus ainda depende, em geral, de processos manuais. Esse registro é sujeito a falhas, difícil de auditar e não fornece dados confiáveis sobre a operação das rotas.

Importância. A falta de um registro confiável tem consequências em três frentes. Na segurança dos estudantes, não é possível afirmar com certeza se um aluno embarcou, se desembarcou no ponto correto ou se ficou para trás. Na transparência da gestão pública, os dados são difíceis de serem coletados e auditados. Na eficiência operacional, a falta de dados impede que os gestores identifiquem rotas subutilizadas, atrasos recorrentes ou o custo real por aluno transportado.

Benefícios esperados. O trabalho propõe um dispositivo de Internet das Coisas (IoT) embarcado no ônibus que identifica automaticamente cada aluno no embarque e no desembarque, por reconhecimento facial e de voz, sem exigir nenhuma ação do motorista e com o mínimo de ação do aluno. Os eventos de presença são enviados ao sistema TRANSCOLAR RURAL, já utilizado na gestão do transporte escolar. Com isso, espera-se: (i) maior segurança física dos estudantes, com alertas imediatos de falha de reconhecimento ou embarque irregular; (ii) registros auditáveis de presença, que dão transparência ao uso dos recursos públicos; e (iii) relatórios de presença, localização, tempo de viagem e eficiência das rotas para os gestores escolares. O sistema é projetado desde o início com foco em privacidade: nenhuma imagem ou áudio dos alunos é armazenado, apenas o evento de presença resultante.

1.4 Objetivos

O **objetivo geral** deste trabalho é projetar e implementar um dispositivo IoT embarcado em ônibus escolares rurais que registre a presença dos alunos por reconhecimento de voz e vídeo, integrando os dados gerados ao sistema TRANSCOLAR RURAL, de modo a aumentar a segurança dos estudantes e a eficiência operacional do transporte escolar.

Os **objetivos específicos** são:

1. desenvolver um protótipo de hardware IoT dotado de câmera e microfone;
2. implementar algoritmos de reconhecimento facial e de voz adequados às condições reais de operação no interior de um ônibus;
3. integrar o dispositivo ao sistema TRANSCOLAR RURAL por meio de rede móvel;
4. viabilizar a geração de relatórios inteligentes voltados a gestores escolares;
5. avaliar o desempenho, a segurança e a confiabilidade do sistema proposto.

1.5 Local de realização

O trabalho é realizado no Departamento de Engenharia Eletrônica (DELT) da Escola de Engenharia da Universidade Federal de Minas Gerais. O DELT atua no ensino e na pesquisa em eletrônica, sistemas embarcados, processamento de sinais e inteligência computacional, áreas em que este projeto se insere: ele combina hardware embarcado, processamento de imagem e áudio e aprendizado de máquina aplicado a um problema de gestão pública.

1.6 Visão geral do documento

- A Seção 2 apresenta uma visão geral do trabalho, caracterizando o seu escopo e efetuando uma breve revisão bibliográfica sobre o assunto, permitindo situar claramente o trabalho proposto em relação a outros apresentados na literatura;
- A Seção 3 descreve a metodologia a ser empregada no trabalho a ser desenvolvido;
- A seção *Referências* apresenta as referências bibliográficas utilizadas.

2 Visão Geral do Trabalho

O trabalho consiste em um dispositivo embarcado instalado na porta do ônibus escolar, composto por câmera, microfone e uma unidade de processamento local. Quando o aluno embarca ou desembarca, o dispositivo detecta o rosto, compara-o com as referências biométricas cadastradas e, opcionalmente, usa a voz como reforço. Todo o reconhecimento

é feito no próprio dispositivo (computação de borda), sem depender de processamento em nuvem. O resultado é indicado na hora ao motorista por um LED e um sinal sonoro, e gera um evento de presença (aluno, ônibus, rota, horário e tipo de evento). A imagem e o áudio capturados são descartados.

Os eventos são enviados ao backend e ao TRANSCOLAR RURAL pela rede móvel, por meio do protocolo MQTT. Como a conectividade nas rotas rurais é intermitente, o dispositivo mantém uma fila local e reenvia os eventos quando a conexão volta, sem perda nem duplicação. A partir desses dados, o sistema gera relatórios de presença, localização, tempo de viagem, segurança, eficiência operacional e qualidade do serviço para os gestores escolares.

O ciclo completo se divide em duas etapas. O **TCC I** cobre a especificação e a concepção: levantamento de requisitos, revisão bibliográfica com avaliação empírica de algoritmos, projeto arquitetural e análise de impactos. O **TCC II** cobre a realização: implementação do software embarcado, integração com o TRANSCOLAR RURAL, simulação, teste piloto em ônibus real e validação das métricas.

2.1 Escopo do trabalho

O que se pretende fazer. Especificar, projetar, implementar e validar, em um piloto com um ônibus, um sistema que contempla:

- reconhecimento facial no embarque e no desembarque, com reconhecimento de voz como reforço;
- retorno local ao motorista por LED e sinal sonoro, sem tela nem login;
- registro de eventos de presença com funcionamento offline e sincronização posterior, sem perda nem duplicação;
- integração com o TRANSCOLAR RURAL via MQTT/API;
- relatórios para gestores escolares;
- cadastro de alunos, rotas, ônibus e referências biométricas, com registro e revogação do consentimento dos responsáveis.

As principais metas quantitativas definidas no levantamento de requisitos são: acurácia de reconhecimento superior a 90%, tempo de no máximo 2 segundos por aluno entre a detecção e o retorno local, e capacidade para cerca de 20 alunos por ônibus no piloto.

O que não se pretende fazer. Não fazem parte do escopo: interfaces (aplicativo, tela ou login) para motoristas, monitores ou responsáveis; a coleta do consentimento dos responsáveis, que é um processo administrativo da escola (o sistema apenas o registra); o

desenvolvimento ou a alteração do próprio TRANSCOLAR RURAL; e o uso de dados reais de alunos durante a prototipagem, que utiliza apenas bases públicas de adultos.

Inserção em um projeto maior. O trabalho complementa o TRANSCOLAR RURAL, sistema já utilizado na gestão do transporte escolar rural. O dispositivo proposto funciona como uma nova fonte automática de dados de presença para esse sistema, que hoje depende de registro manual. Caso a interface com esse sistema não esteja disponível para integração com o projeto em desenvolvimento (esse ponto ainda será definido), a integração será validada contra um serviço simulado que segue o mesmo formato de mensagem; como o envio fica isolado em um único componente do software embarcado, a troca pelo serviço real não altera o restante do sistema.

Situação atual e situação a ser alcançada. Atualmente, o controle de presença nos ônibus é manual, sem registro auditável e sem dados operacionais consolidados. Ao final do trabalho, espera-se um protótipo validado em um ônibus real que registre automaticamente o embarque e o desembarque de cada aluno, alerte em caso de falha ou embarque irregular, funcione mesmo sem sinal de rede e entregue esses dados ao TRANSCOLAR RURAL. Tudo isso respeitando a Lei Geral de Proteção de Dados Pessoais (LGPD) (BRASIL, 2018), por se tratar de dados biométricos de menores de idade.

2.2 Revisão bibliográfica

Os primeiros sistemas automáticos de reconhecimento facial tratavam a imagem inteira como um vetor de pixels. No Eigenfaces, Turk e Pentland (1991) usam análise de componentes principais (PCA) para descrever cada rosto por poucos coeficientes, e o próprio artigo mostra o limite da ideia: o acerto ficou perto de 96% quando só a iluminação variava, mas caiu para 64% quando variava o tamanho do rosto na imagem. O Fisherfaces (BELHUMEUR; HESPANHA; KRIEGMAN, 1997) troca a PCA pela análise discriminante linear, que usa os rótulos do treino para separar as pessoas, e não as condições de luz. Já o LBPH (AHONEN; HADID; PIETIKÄINEN, 2004) descreve o rosto pela textura local de cada região, com histogramas de padrões binários. São métodos baratos, que rodariam com folga em qualquer placa embarcada, mas a variação de luz e de ângulo que os prejudica é exatamente o que se espera na porta de um ônibus. Por isso aparecem aqui só como ponto de partida histórico.

A mudança veio com as redes profundas treinadas para produzir um vetor de características (*embedding*) em que a distância entre dois vetores já mede a semelhança entre dois rostos. O FaceNet (SCHROFF; KALENICHENKO; PHILBIN, 2015) aprende esse espaço com a *triplet loss*, que compara trios de imagens (duas da mesma pessoa e uma de outra), e chegou a 99,63% de acurácia na LFW. Para este projeto, a consequência prática é que cadastrar um aluno novo exige só guardar o *embedding* da sua foto, sem treinar a rede de novo. Os trabalhos seguintes passaram a medir a semelhança pelo ângulo entre os vetores. O ArcFace (DENG et al., 2019) soma uma margem fixa ao ângulo entre o *embedding* e

o centro da classe correta e chegou a 99,83% na LFW. O SFace (ZHONG et al., 2021) suaviza essa otimização com curvas sigmoides, para que fotos ruins e rótulos errados da base de treino não dominem o aprendizado. No benchmark deste trabalho (Tabela 1), o ArcFace também foi o modelo mais preciso, enquanto o SFace, com apenas 5 MB, foi de longe o mais rápido.

Antes de qualquer comparação, o rosto precisa ser encontrado e alinhado, e essa etapa acabou pesando tanto quanto o modelo. O RetinaFace (DENG et al., 2020) prevê, numa só passada da rede, a caixa do rosto e cinco pontos de referência, e lida bem com rostos pequenos. Com ele, a acurácia do ArcFace no benchmark subiu de 92,97% para 96,61%, ao custo de cerca de 0,6 s por imagem na CPU. O YuNet (WU; PENG; YU, 2023) vai no sentido oposto: tem cerca de 76 mil parâmetros, código aberto e roda em poucos milissegundos na CPU, com precisão menor que a do RetinaFace nos rostos mais difíceis. Se essa perda é aceitável dentro do ônibus é uma das perguntas que a próxima rodada do benchmark deve responder.

Para comparar os modelos em condições iguais, foi usada a biblioteca DeepFace (SERENGIL; OZPINAR, 2020), que aplica o mesmo pipeline de detecção, alinhamento e verificação a todos eles. Os autores da biblioteca lembram que o alinhamento muda o resultado: no FaceNet, ele elevou a acurácia na LFW de 98,87% para 99,63%. Os testes usam apenas uma base pública de adultos, a *Labeled Faces in the Wild* (LFW) (HUANG et al., 2007), com 13.233 fotos de 5.749 pessoas tiradas de notícias, em condições não controladas.

Para levar os eventos ao servidor, o projeto usa o MQTT (OASIS, 2019), um protocolo leve de publicação e assinatura pensado para redes instáveis. No nível de qualidade de serviço 1, o *broker* confirma o recebimento de cada mensagem, e é essa confirmação que permite ao dispositivo apagar um evento da fila local só depois de entregue. Numa rota rural, em que o sinal de celular cai com frequência, isso faz diferença.

A voz entra como reforço do rosto. No TCC I ela fica restrita à revisão bibliográfica, e a escolha e a avaliação do modelo de reconhecimento de locutor ficam para o TCC II. A lógica é a mesma do reconhecimento facial. No ECAPA-TDNN (DESPLANQUES; THIENPONDT; DEMUYNCK, 2020), que superou os sistemas baseados em x-vector e em ResNet da época, uma rede extrai um *embedding* de cada trecho de fala, e dois trechos são comparados pela distância de cosseno entre os vetores, como se faz com os rostos. A versão menor do modelo tem 6,2 milhões de parâmetros e taxa de erro igual (EER) de 1,01% no VoxCeleb1. Essa base (NAGRANI; CHUNG; ZISSERMAN, 2017), com mais de 100 mil falas de 1.251 celebridades tiradas de vídeos do YouTube, tem para a voz o papel que a LFW tem para o rosto: as gravações vêm de ambientes reais, como entrevistas, estádios e tapetes vermelhos, com ruído e várias pessoas falando. O ruído de um ônibus, porém, é outro: o motor, a estrada e a conversa dos próprios alunos devem piorar a taxa de acerto. O ECAPA-TDNN já é treinado com ruído, fala de fundo e reverberação artificiais, mas

isso não garante o desempenho dentro do ônibus, e o ruído vai pesar tanto na escolha do modelo quanto na do microfone direcional.

Há trabalhos anteriores com a mesma motivação. Em ônibus escolares, Garg et al. (2021) registram o embarque e o desembarque com cartões RFID e avisam os pais por SMS ou e-mail. Como o cartão exige uma ação do aluno e pode ser usado por outra pessoa, os autores acrescentam uma câmera ESP32-CAM com reconhecimento facial para confirmar quem embarca. Em sala de aula, o trabalho mais próximo deste é o de Duarte, Pereira e Matos (2025), que usa a mesma combinação de Raspberry Pi, DeepFace e ArcFace. Os números deles ajudam a dimensionar o problema: o reconhecimento levou cerca de 4,5 s no próprio Raspberry Pi 4 e caiu para cerca de 2 s quando foi transferido a um computador na rede local. O acerto foi de 85,7% entre 14 voluntários, abaixo dos 90% que o mesmo par de detector e modelo havia obtido com fotos.

O que este trabalho acrescenta é juntar essas peças sob as restrições do transporte rural. O reconhecimento roda inteiro no dispositivo, sem depender de rede, ao contrário do CLASSIC, que precisa de um computador na mesma rede Wi-Fi para ser rápido. Quando o sinal cai, os eventos esperam numa fila local e são enviados depois, sem perda nem duplicação. Nenhuma imagem é guardada, enquanto o CLASSIC armazena todas as fotos capturadas, um ponto sensível pela LGPD quando os dados são de crianças. E os eventos alimentam um sistema público que já existe, o TRANSCOLAR RURAL.

3 Metodologia e Cronograma

3.1 Atividades do TCC I

Atividade 1.1 – Levantamento de requisitos. Os requisitos funcionais e não funcionais foram levantados a partir da proposta do projeto e de decisões tomadas com a orientação. Eles estão consolidados em um documento de requisitos com identificadores rastreáveis até os objetivos específicos. Entre as decisões já tomadas estão: não armazenar imagem nem áudio dos alunos; tempo máximo de 2 s por reconhecimento; retorno local por LED e bipe; retenção dos eventos no dispositivo apenas até a sincronização e, no servidor, pelo ano letivo mais um ano; registro do consentimento dos responsáveis como pré-requisito para o cadastro biométrico; e, entre os dois tipos de erro de reconhecimento, considerar mais grave registrar o aluno errado (falso positivo) do que deixar de registrar um aluno (falso negativo), já que este último ainda é sinalizado ao motorista pelo retorno local de falha.

Atividade 1.2 – Revisão bibliográfica e avaliação empírica. Além da pesquisa bibliográfica, foi feito um benchmark com os dez modelos de reconhecimento facial disponíveis na biblioteca DeepFace: VGG-Face (PARKHI; VEDALDI; ZISSERMAN, 2015), FaceNet e FaceNet512 (SCHROFF; KALENICHENKO; PHILBIN, 2015), OpenFace (AMOS;

LUDWICZUK; SATYANARAYANAN, 2016), DeepFace (TAIGMAN et al., 2014), DeepID (SUN; WANG; TANG, 2014), ArcFace (DENG et al., 2019), Dlib (KING, 2009), SFace (ZHONG et al., 2021) e GhostFaceNet (ALANSARI et al., 2023). O FaceNet512 é uma versão de 512 dimensões treinada pela comunidade, sem artigo próprio; o modelo Dlib vem da biblioteca de mesmo nome. A ferramenta foi escolhida porque aplica o mesmo pipeline de detecção e alinhamento a todos os modelos, o que garante uma comparação justa. Cada modelo foi avaliado em 384 pares de imagens da base LFW (96 pessoas, com pares da mesma pessoa e de pessoas diferentes), medindo acurácia, precisão, *recall*, F1, tempo médio por par e tamanho do modelo. Cada modelo roda em um processo separado, para que o tempo medido não seja distorcido pelos modelos carregados antes. O benchmark foi rodado com dois detectores de rosto: o do OpenCV, baseado no Haar Cascade (VIOLA; JONES, 2001), mais leve, e o RetinaFace (DENG et al., 2020), mais preciso. Cada imagem é detectada e alinhada uma única vez, e os dez modelos são avaliados sobre os mesmos recortes, o que permite medir o tempo de detecção separado do tempo de reconhecimento. A Tabela 1 mostra os modelos mais bem colocados.

Tabela 1 – Resultados preliminares do benchmark (384 pares da base LFW, limiar padrão do DeepFace). O tempo por par inclui a detecção das duas imagens, medida na CPU de um computador pessoal.

	OpenCV		**RetinaFace**		
Modelo	**Acurácia**	**Tempo (s)**	**Acurácia**	**Tempo (s)**	**MB**
ArcFace	92,97%	0,56	96,61%	1,80	130
VGG-Face	88,02%	1,06	95,57%	2,34	580
Dlib	84,64%	1,08	84,90%	2,30	22
Facenet	76,30%	0,64	82,55%	1,85	90
GhostFaceNet	82,03%	0,51	81,77%	1,71	16
SFace	81,25%	0,09	79,69%	1,28	5

O **ArcFace** é a escolha mais clara: tem a maior acurácia com os dois detectores e chega a 96,61% com o RetinaFace, acima da meta de 90%, com precisão de 99,45%. O segundo modelo ainda está em aberto. O VGG-Face também passa da meta com o RetinaFace (95,57%), mas é o maior modelo avaliado (580 MB). O SFace é de longe o mais leve e rápido (5 MB e 0,04 s de reconhecimento por par), mas fica abaixo de 82% com os dois detectores.

Os resultados também mostram três pontos que orientam os próximos passos. Primeiro, o detector pesa tanto quanto o modelo de reconhecimento: o RetinaFace leva cerca de 0,6 s por imagem na CPU, e com ele o ArcFace fica em 1,80 s por par, perto do limite de 2 s, o que torna a escolha do detector parte da decisão. Segundo, SFace, GhostFaceNet e Dlib têm precisão próxima de 100% e *recall* baixo com qualquer detector, o que aponta para o limiar padrão do DeepFace, conservador demais para esses modelos, e não para uma limitação deles. Como o critério do projeto prioriza a precisão, a comparação final vai

fixar uma meta de precisão, calibrar o limiar de cada modelo em um conjunto separado e comparar o *recall* obtido nesse ponto. Terceiro, com 384 pares a margem de erro é de cerca de 2 pontos percentuais, de modo que ArcFace e VGG-Face ainda não se distinguem estatisticamente. Até o fim de outubro, o benchmark será repetido com o detector YuNet, os limiares serão calibrados, os dois modelos serão escolhidos e a base de dados será ampliada para testá-los com mais rigor.

Uma limitação deve ser registrada: o benchmark mede verificação 1:1 entre fotos de adultos, enquanto o sistema fará identificação entre cerca de 20 crianças, com a iluminação e o ângulo da porta do ônibus. Os números servem para comparar os modelos entre si; o desempenho real só será conhecido nos testes do TCC II.

Atividade 1.3 – Projeto arquitetural e análise de trade-offs. Nesta atividade, será definida a arquitetura de hardware e software, com modelagem do banco de dados e diagramas UML (casos de uso, componentes, sequência do fluxo de embarque e implantação). Também será feita uma análise de trade-off entre computação de borda com Raspberry Pi e microcontrolador ESP32, considerando custo, capacidade de processamento e a possibilidade de rodar os modelos escolhidos dentro do limite de 2 s. A tendência atual é usar Raspberry Pi 5 com o acelerador AI HAT (Hailo-10), já que o ESP32 não tem memória nem capacidade de processamento para rodar com folga os modelos de reconhecimento avaliados. Também serão especificados a câmera, o microfone direcional e o banco de dados (PostgreSQL ou Firebase). Por fim, será estudado como emular o ambiente do Hailo-10 no computador, para antecipar os testes de desempenho. Os primeiros diagramas (contexto, casos de uso, componentes, implantação, sequência do embarque e da sincronização e modelo de dados) já estão esboçados. Para o software embarcado, foi adotada uma arquitetura de portas e adaptadores, em que a câmera, o modelo de reconhecimento e o meio de envio ficam atrás de interfaces e podem ser trocados sem alterar a regra de negócio, e uma fila local de eventos com identificador único por evento, que garante o envio sem perda nem duplicação quando a rede volta.

Atividade 1.4 – Avaliação de impactos. Serão analisados os impactos socioeconômicos (segurança física dos estudantes, transparência e otimização dos recursos públicos), legais (tratamento de dados biométricos de menores de idade segundo a LGPD, base legal, consentimento e prazos de retenção) e ambientais (consumo de energia e descarte do hardware) da tecnologia proposta.

Atividades 1.5 e 1.6 – Monografia e seminário. Redação do texto inicial da monografia (Introdução, Revisão Bibliográfica, Metodologia, Avaliação de Impactos e Cronograma do TCC II), finalização do texto e preparação da apresentação no Seminário de TCC I.

Ferramentas. Python com OpenCV e TensorFlow Lite no pré-processamento e inferência no dispositivo, biblioteca DeepFace na avaliação comparativa dos modelos, MQTT na comunicação com o backend, PostgreSQL ou Firebase para armazenamento

e LaTeX/Overleaf para as documentações. Python e OpenCV foram escolhidos pela maturidade em visão computacional e pelo suporte a hardware embarcado. O TensorFlow Lite foi escolhido por ser otimizado para inferência em dispositivos com poucos recursos. O MQTT, pelos motivos discutidos na revisão bibliográfica. O Claude Code foi utilizado para estruturação da documentação, acompanhamento do cronograma, geração de relatórios de status, apoio no levantamento de questionamentos para os requisitos, apoio na revisão do conteúdo produzido, tradução de algumas documentações e apoio no entendimento, geração de resumos e indicação de fontes de pesquisa para serem estudadas.

3.2 Atividades do TCC II

1. **Implementação do software embarcado:** pipeline de captura, detecção, reconhecimento facial e de voz (incluindo a seleção e a avaliação do modelo de reconhecimento de locutor), retorno local por LED e bipe, e fila local de eventos.

2. **Integração:** comunicação MQTT/API com o backend e o TRANSCOLAR RURAL, com sincronização offline sem perda nem duplicação, e módulo de cadastro e relatórios.

3. **Simulação em ambiente controlado:** testes de acurácia e de tempo de resposta com o hardware definitivo, simulando as condições do ônibus (iluminação, movimento, perda de conexão).

4. **Teste piloto:** instalação em um ônibus escolar rural real, com cerca de 20 alunos.

5. **Validação e redação:** comparação das métricas obtidas com as metas (acurácia acima de 90%, no máximo 2 s por aluno), redação da monografia de TCC II e defesa.

3.3 Cronograma

Tabela 2 – Cronograma do ciclo completo do TCC.

Data limite	**Etapa**
TCC I	
08/2026	1.1 – Levantamento de requisitos funcionais e não funcionais
30/09/2026	1.2 – Seleção de 10 algoritmos, implementação do benchmark e obtenção da base de dados de teste
18/10/2026	Entrega deste documento de Visão Geral
31/10/2026	1.2 – Benchmark com os dados iniciais, escolha dos 2 melhores algoritmos e ampliação da base de dados
31/10/2026	1.3 – Projeto arquitetural, modelagem de banco de dados e diagramas UML
31/10/2026	1.4 – Análise de impactos socioeconômicos, ambientais e de privacidade
13/11/2026	1.5 – Entrega do texto inicial da monografia
16 a 19/11/2026	1.6 – Seminários de TCC I
30/11/2026	1.3 – Estudo da emulação do Raspberry Pi AI HAT (Hailo-10) no computador
TCC II	
03/2027	2.1 – Implementação do software embarcado
04/2027	2.2 – Integração MQTT/API com o TRANSCOLAR RURAL
05/2027	2.3 – Simulação em ambiente controlado
06/2027	2.4 – Teste piloto em ônibus escolar rural
07/2027	2.5 – Validação de métricas, monografia de TCC II e defesa

Referências

AHONEN, T.; HADID, A.; PIETIKÄINEN, M. Face recognition with local binary patterns. In: *Computer Vision – ECCV 2004*. Berlin: Springer, 2004. (Lecture Notes in Computer Science, v. 3021), p. 469–481.

ALANSARI, M. et al. GhostFaceNets: Lightweight face recognition model from cheap operations. *IEEE Access*, v. 11, p. 35429–35446, 2023.

AMOS, B.; LUDWICZUK, B.; SATYANARAYANAN, M. *OpenFace: A General-Purpose Face Recognition Library with Mobile Applications*. 2016. Relatório técnico CMU-CS-16-118, School of Computer Science, Carnegie Mellon University, Pittsburgh.

BELHUMEUR, P. N.; HESPANHA, J. P.; KRIEGMAN, D. J. Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 19, n. 7, p. 711–720, 1997.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)*. 2018. Diário Oficial da União. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>.

DENG, J. et al. RetinaFace: Single-shot multi-level face localisation in the wild. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Seattle: IEEE, 2020. p. 5202–5211.

DENG, J. et al. ArcFace: Additive angular margin loss for deep face recognition. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Long Beach: IEEE, 2019. p. 4685–4694.

DESPLANQUES, B.; THIENPONDT, J.; DEMUYNCK, K. ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification. In: *Proceedings of Interspeech 2020*. Shanghai: ISCA, 2020. p. 3830–3834.

DUARTE, M. G.; PEREIRA, M. B.; MATOS, F. de. CLASSIC: Sistema de chamada escolar com reconhecimento facial através de IoT e computação de borda. In: *Anais do XIX Simpósio Brasileiro de Componentes, Arquiteturas e Reutilização de Software (SBCARS)*. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 58–66.

GARG, B. et al. IoT based smart school bus security system. *Turkish Online Journal of Qualitative Inquiry (TOJQI)*, v. 12, n. 4, p. 1251–1260, abr. 2021.

HUANG, G. B. et al. *Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments*. 2007. Relatório técnico 07-49, University of Massachusetts, Amherst.

KING, D. E. Dlib-ml: A machine learning toolkit. *Journal of Machine Learning Research*, v. 10, p. 1755–1758, 2009.

NAGRANI, A.; CHUNG, J. S.; ZISSERMAN, A. VoxCeleb: a large-scale speaker identification dataset. In: *Proceedings of Interspeech 2017*. Stockholm: ISCA, 2017. p. 2616–2620.

OASIS. *MQTT Version 5.0*. 2019. OASIS Standard. Disponível em: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>.

PARKHI, O. M.; VEDALDI, A.; ZISSERMAN, A. Deep face recognition. In: *Proceedings of the British Machine Vision Conference (BMVC)*. [S.l.]: BMVA Press, 2015. p. 41.1–41.12.

SCHROFF, F.; KALENICHENKO, D.; PHILBIN, J. FaceNet: A unified embedding for face recognition and clustering. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Boston: IEEE, 2015. p. 815–823.

SERENGIL, S. I.; OZPINAR, A. LightFace: A hybrid deep face recognition framework. In: *2020 Innovations in Intelligent Systems and Applications Conference (ASYU)*. Istanbul: IEEE, 2020. p. 1–5.

SUN, Y.; WANG, X.; TANG, X. Deep learning face representation from predicting 10,000 classes. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Columbus: IEEE, 2014. p. 1891–1898.

TAIGMAN, Y. et al. DeepFace: Closing the gap to human-level performance in face verification. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Columbus: IEEE, 2014. p. 1701–1708.

TURK, M.; PENTLAND, A. Eigenfaces for recognition. *Journal of Cognitive Neuroscience*, MIT Press, v. 3, n. 1, p. 71–86, 1991.

VIOLA, P.; JONES, M. Rapid object detection using a boosted cascade of simple features. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Kauai: IEEE, 2001. v. 1, p. 511–518.

WU, W.; PENG, H.; YU, S. YuNet: A tiny millisecond-level face detector. *Machine Intelligence Research*, v. 20, n. 5, p. 656–665, 2023.

ZHONG, Y. et al. SFace: Sigmoid-constrained hypersphere loss for robust face recognition. *IEEE Transactions on Image Processing*, v. 30, p. 2587–2598, 2021.